

O Custo da Granularidade Semântica na Detecção de Resíduos: um Estudo Controlado com TACO e YOLO26n

Nome do(a) Autor(a)¹

¹Instituição do(a) Autor(a)

Cidade – Estado – Brasil

email@exemplo.com

Resumo. A detecção de resíduos em cenas não controladas combina localização com uma decisão semântica cuja dificuldade depende da taxonomia. Este trabalho quantifica esse custo no TACO usando as mesmas imagens e caixas em três taxonomias: 60 classes detalhadas, seis grupos por material e uma classe para resíduo. Modelos YOLO26n foram treinados sob protocolo idêntico com três sementes e avaliados em teste fixo. O AP_{50} médio foi $0,146 \pm 0,022$, $0,183 \pm 0,023$ e $0,567 \pm 0,002$ para Fine, Material e Binary. Ao reavaliar as mesmas detecções Fine após remapeamento hierárquico, o AP_{50} passou de $0,103 \pm 0,007$ para $0,171 \pm 0,015$ no nível de material e $0,466 \pm 0,014$ sem distinção de classe. Um bootstrap pareado confirmou ganhos significativos nos remapeamentos, enquanto a diferença direta de AP entre Fine e Material permaneceu inconclusiva. Classes raras obtiveram AP e revocação substancialmente inferiores. Os resultados indicam que a discriminação semântica sob cauda longa, mais que a localização isolada, é um gargalo central; a taxonomia por material constitui um compromisso útil, embora sua superioridade em AP não seja estatisticamente definitiva.

1. Introdução

Detectar resíduos em ambientes externos é diferente de reconhecer itens em condições controladas: os objetos podem ser pequenos, deformáveis, transparentes, ocluídos ou visualmente confundidos com o fundo. O TACO (*Trash Annotations in Context*) foi criado para representar esse cenário, reunindo fotografias de ambientes diversos e uma taxonomia hierárquica de resíduos [Proença and Simões 2020]. Entretanto, sua versão oficial contém apenas 1.500 imagens e 4.784 instâncias distribuídas em 60 categorias, combinação que impõe simultaneamente poucos dados e forte desbalanceamento.

Em detecção multiclasse, uma caixa espacialmente correta é considerada erro quando recebe a classe errada. Assim, o desempenho pode diminuir tanto por falhas de localização quanto pela exigência de distinguir categorias visualmente próximas e pouco representadas. A granularidade da taxonomia determina quanta informação semântica se exige do modelo, mas comparações entre estudos costumam misturar arquiteturas, partições e agrupamentos diferentes. Isso impede atribuir a variação de desempenho apenas aos rótulos.

Este trabalho investiga: *como a granularidade das classes afeta a detecção de resíduos em um conjunto pequeno e de cauda longa, e quanto da perda decorre de localização versus discriminação semântica?* Para isolar essa variável, fixamos imagens, caixas, partição e protocolo de treino, alterando somente a taxonomia: Fine (60 classes oficiais),

Material (seis macroclasses) e Binary (uma classe *Litter*). Empregamos o YOLO26n, variante compacta da família YOLO26 [Jocher et al. 2026], sem modificar sua arquitetura.

As contribuições são: (i) comparação controlada dos três níveis com três sementes; (ii) avaliação hierárquica das *mesmas* predições Fine, remapeadas para material e para classe única; (iii) intervalos de confiança por bootstrap pareado por imagem; e (iv) análise multissemente de cauda longa e uma decomposição auditável dos erros. Todo número apresentado é produzido por scripts a partir das anotações, configurações, checkpoints ou predições salvas.

2. Trabalhos Relacionados

Proença e Simões [Proença and Simões 2020] introduziram o TACO com 60 categorias pertencentes a 28 supercategorias. Reconhecendo a ambiguidade visual e o desbalanceamento, os autores avaliaram Mask R-CNN em TACO-1, sem classes, e TACO-10, com nove supercategorias frequentes e uma classe residual. Portanto, agrupamento de rótulos no TACO não é inédito. Nosso recorte difere por estabelecer três níveis ordenados, incluir um nível intermediário por material e reavaliar hierarquicamente as mesmas detecções para separar localização de semântica.

Córdova et al. [Córdova et al. 2022] compararam Faster R-CNN, Mask R-CNN, RetinaNet, EfficientDet e YOLOv5 em TACO e PlastOPol, relatando dificuldades com objetos pequenos e cenários naturais complexos. O estudo mostra a relevância de detectores YOLO leves, mas seus números não são diretamente comparáveis aos nossos: taxonomia, partição, versões dos modelos e protocolo diferem. Aqui o objetivo não é estabelecer estado da arte, e sim medir uma variável experimental.

YOLO surgiu como detector de estágio único orientado a inferência em tempo real [Redmon et al. 2016]. O YOLO26 unifica modelos atuais da Ultralytics e oferece uma cabeça *end-to-end* sem NMS, além de mecanismos de atribuição voltados a objetos pequenos [Jocher et al. 2026]. Selecionamos a variante nano por compatibilidade com uma GPU de 6 GB; não comparamos arquiteturas.

Distribuições de cauda longa são conhecidas por prejudicar categorias com poucos exemplos. O LVIS formalizou esse desafio em detecção e segmentação de grande vocabulário [Gupta et al. 2019]; perdas balanceadas por classe são uma linha de mitigação [Cui et al. 2019]. Neste estudo não alteramos amostragem ou função de perda, pois isso adicionaria fatores experimentais. Em vez disso, medimos o desempenho nos estratos raro, médio e frequente.

3. Metodologia

A Figura 1 sintetiza o desenho experimental. A partir de uma única versão auditada do TACO, mantemos a partição e as caixas constantes, derivamos três taxonomias, treinamos cada uma sob protocolo idêntico e aplicamos cinco análises complementares no mesmo conjunto de teste.




Figura 1. Pipeline experimental. Somente a taxonomia varia entre os três ramos de treinamento; imagens, caixas, partição, arquitetura e hiperparâmetros permanecem fixos.

3.1. Dados, auditoria e partição

Usamos exclusivamente `data/annotations.json` do repositório oficial TACO, em formato COCO [Lin et al. 2014], e somente *bounding boxes*. A auditoria programática confirmou 1.500 imagens, 4.784 objetos, 60 categorias, nenhuma imagem vazia e nenhum arquivo ausente. Sete caixas excediam a borda em no máximo 1,32 pixel; elas foram recortadas apenas na conversão, mantendo o JSON oficial intacto e registrando cada alteração.

A partição foi sorteada uma vez por imagem com semente 42: treino, validação e teste receberam, respectivamente, 1.050/225/225 imagens e 3.359/788/637 objetos. As três taxonomias reutilizam exatamente essa partição. As coordenadas COCO (x, y, w, h) foram convertidas para centro, largura e altura normalizados do YOLO; scripts verificaram limites, dimensões positivas, IDs e igualdade das partições. Imagens com orientação EXIF foram transpostas fisicamente antes da conversão.




Figura 2. Instâncias de treino das 60 classes Fine, ordenadas por frequência. As linhas marcam os limiares da análise de cauda longa.

3.2. Taxonomias

Fine preserva as 60 categorias oficiais. Material remapeia todas elas para Plastic (24 categorias de origem), Metal (9), Glass (4), Paper/Cardboard (13), Organic (1) e Other (9). Compostos ou itens sem associação natural, como bateria, sapato e embalagens multi-camadas, foram enviados a Other; cada decisão e sua justificativa estão em `configs/material_mapping.json`. Binary atribui *Litter* a todas as instâncias. As caixas não mudam entre versões. A Figura 2 evidencia a cauda longa que motiva os agrupamentos.

3.3. Modelo e protocolo experimental

Treinamos YOLO26n inicializado com pesos COCO, entrada 640×640 , lote 24, até 60 épocas, *early stopping* com paciência 15, AdamW [Loshchilov and Hutter 2019] e taxa inicial 10^{-3} . Foram mantidas as transformações padrão da implementação Ultralytics, precisão mista e determinismo. Todos os experimentos usaram Python 3.12.10, PyTorch 2.8.0+cu128 e Ultralytics 8.4.157 em uma RTX 3060 Laptop de 6 GB. As sementes 42, 123 e 2026 foram aplicadas às três taxonomias; não houve ajuste específico por configuração.

3.4. Avaliação e incerteza

No teste fixo, reportamos precisão, revocação, F_1 , AP_{50} e $AP_{50:95}$ da implementação Ultralytics; esta última média usa IoU de 0,50 a 0,95 em passos de 0,05. A Tabela principal apresenta média e desvio-padrão entre sementes.

Para decompor o erro, um avaliador controlado faz casamento guloso um-para-um em ordem decrescente de confiança e AP interpolado em 101 pontos. Para cada modelo Fine, preservamos caixas e escores, mas remapeamos predição e verdade-terreno para Fine, Material ou Binary. Como essa implementação não é numericamente idêntica ao avaliador nativo, seus valores só são comparados entre si.

Aplicamos bootstrap percentil pareado [Efron and Tibshirani 1993] para obter ICs de 95%. Fizemos 2.000 reamostragens das 225 imagens de teste, com reposição e os mesmos índices nos dois lados. O bootstrap usa as predições da semente 42; as outras análises agregam três sementes. Para cauda longa, a frequência é calculada apenas no treino: rara ($n \leq 19$), média ($20 \leq n \leq 100$) e frequente ($n > 100$).

4. Resultados

4.1. Efeito da taxonomia

A Tabela 1 resume os modelos treinados. Material elevou o AP_{50} médio de 0,146 para 0,183 e o F_1 de 0,232 para 0,296 em relação a Fine. Binary alcançou 0,567 de AP_{50} e apresentou a menor variação entre sementes ($\sigma = 0,002$). Esse ganho não constitui uma comparação de capacidade semântica equivalente: Binary só precisa separar resíduo de fundo.

Tabela 1. Teste por taxonomia: média $\pm$ desvio-padrão de três sementes.

Taxonomia	P	R	F_1	AP_{50}	$AP_{50:95}$
Fine	0.360 $\pm$ 0.063	0.173 $\pm$ 0.010	0.232 $\pm$ 0.005	0.146 $\pm$ 0.022	0.118 $\pm$ 0.022
Material	0.387 $\pm$ 0.050	0.241 $\pm$ 0.012	0.296 $\pm$ 0.006	0.183 $\pm$ 0.023	0.131 $\pm$ 0.023
Binary	0.750 $\pm$ 0.050	0.491 $\pm$ 0.018	0.593 $\pm$ 0.004	0.567 $\pm$ 0.002	0.405 $\pm$ 0.005

No bootstrap controlado da semente 42, a diferença Fine–Material em AP_{50} foi $-0,032$, IC95% $[-0,079; 0,008]$; em $AP_{50:95}$, $-0,012$, IC95% $[-0,049; 0,019]$. Ambos incluem zero, logo os dados não sustentam superioridade inequívoca em AP. Para F_1 , a diferença foi $-0,055$, IC95% $[-0,118; -0,001]$, favorável a Material, embora próxima do limite.

4.2. Localização versus semântica

A Tabela 2 usa exclusivamente as predições dos modelos Fine e o avaliador controlado. Ao aceitar a macroclasse de material, AP_{50} passou de 0,103 para 0,171; ao ignorar classes, chegou a 0,466. No bootstrap da semente 42, os ganhos Material–Fine e Binary–Fine foram, respectivamente, $+0,072$ (IC95% $[0,026; 0,127]$) e $+0,357$ (IC95% $[0,305; 0,409]$). Como caixas e escores são os mesmos, esses aumentos quantificam erros removidos apenas ao relaxar a exigência semântica.

Tabela 2. Mesmas predições Fine avaliadas em três níveis pelo avaliador controlado (média $\pm$ desvio-padrão).

Nível de avaliação	F_1	AP_{50}	$AP_{50:95}$
Fine	0.168 ± 0.016	0.103 ± 0.007	0.082 ± 0.005
Material	0.264 ± 0.021	0.171 ± 0.015	0.122 ± 0.010
Binary	0.506 ± 0.011	0.466 ± 0.014	0.322 ± 0.011




Figura 3. À esquerda, modelos treinados separadamente e avaliados pelo Ultralytics; à direita, mesmas predições Fine remapeadas e avaliadas pelo protocolo controlado. Barras de erro: um desvio-padrão entre sementes.

4.3. Cauda longa e tipos de erro

A Tabela 3 mostra crescimento monotônico com a frequência. Classes raras obtiveram $AP_{50} = 0,046$ e recall 0,030, enquanto as frequentes atingiram 0,207 e 0,282. Logo, a dificuldade Fine não se distribui uniformemente entre rótulos.

Tabela 3. Desempenho Fine por frequência no treino, agregado em três sementes.

Grupo	#classes	n_{treino}	AP_{50}	Recall
Raras	28	5.1	0.046 ± 0.009	0.030 ± 0.007
Médias	22	43.9	0.098 ± 0.022	0.198 ± 0.049
Frequentes	10	225.1	0.207 ± 0.017	0.282 ± 0.019

Como diagnóstico adicional, na semente 42 e limiar de confiança 0,25, o casamento sem classe em $IoU \geq 0,5$ produziu 97 acertos Fine, 51 confusões dentro do mesmo material e 73 entre materiais. Houve ainda 43 predições com sobreposição $0,1 \leq IoU < 0,5$, classificadas como falhas de localização, 42 falsos positivos com $IoU < 0,1$ e 416 objetos não detectados. Esses totais dependem do limiar e servem para caracterização, não como substitutos das curvas de AP.

A Figura 4 liga essa decomposição às imagens de teste. A primeira linha apresenta o mesmo recorte sem anotações, com a verdade-terreno e com uma saída correta. Na segunda, uma lata é localizada corretamente, mas confundida com aerossol, preservando o material; uma embalagem metálica é confundida com papel/cartão; e uma predição sobre latas não atinge o limiar de IoU. Assim, os exemplos ilustram erros semanticamente distintos mesmo quando há evidência visual e sobreposição espacial.




Figura 4. Casos reais do teste Fine, semente 42. A primeira linha separa entrada, anotação e saída correta; a segunda exemplifica confusão intra-material, confusão inter-material e falha de localização. As imagens foram recortadas apenas para legibilidade.

5. Discussão

Os resultados apoiam parcialmente a hipótese de que reduzir granularidade melhora a detecção. Material apresentou médias superiores a Fine, sobretudo em F_1 , mas o IC pareado de AP inclui zero. Portanto, “menos classes é melhor” seria uma conclusão excessiva. Binary é claramente mais fácil, porém responde a outra pergunta operacional e perde toda informação sobre composição do resíduo.

A evidência mais forte vem da avaliação hierárquica. Quando uma caixa Fine recebe crédito após remapeamento, nenhuma propriedade geométrica ou confiança muda. O salto significativo nos dois níveis indica que muitas detecções contêm informação espacial útil, mas falham sob rótulos detalhados. Ainda assim, o AP binário controlado permanece abaixo de 0,5, e a decomposição registra muitas omissões; localização também está longe de resolvida.

A cauda longa oferece uma explicação complementar. As 28 classes raras têm, em média, somente 5,1 instâncias de treino e desempenho muito inferior às dez frequentes. Isso é consistente com a literatura de detecção de grande vocabulário [Gupta et al. 2019], mas aqui não demonstra causalidade isolada: tamanho, oclusão, contexto e semelhança visual também variam entre classes. A macroclasse Material compartilha dados entre rótulos relacionados e preserva uma informação potencialmente útil à triagem, constituindo compromisso plausível entre especificidade e robustez.

Há quatro ameaças principais à validade. Primeiro, uma única partição fixa não mede variação de amostragem; as três sementes medem somente a instabilidade de otimização. Segundo, o bootstrap cobre a semente 42 e condiciona-se ao teste observado. Terceiro, o mapeamento por material é uma decisão de projeto: compostos foram enviados a Other, e Organic contém apenas *Food waste*. Quarto, não comparamos diretamente nossos números aos de trabalhos anteriores devido a diferenças de tarefa e protocolo. Estudos futuros devem repetir partições, avaliar agrupamentos alternativos e testar técnicas de balanceamento sem alterar simultaneamente outros componentes.

6. Conclusão

Este estudo controlado mostrou que a granularidade semântica altera substancialmente a leitura do desempenho no TACO. A taxonomia Material melhorou médias de AP e F_1 frente a Fine, mas apenas o ganho de F_1 foi sustentado pelo bootstrap direto da semente analisada. Ao reavaliar as mesmas caixas Fine, relaxar rótulos para material e classe única gerou aumentos significativos, evidenciando um gargalo semântico. A degradação de classes raras reforça que esse gargalo está associado à escassez e ao desbalanceamento. Assim, a taxonomia deve ser escolhida pela informação exigida pela aplicação, e não apenas pela maior métrica. A pipeline disponibiliza configurações, mapeamento integral, partição, predições, scripts e artefatos derivados para reprodução e extensão do estudo.

Referências

Córdova, M., Pinto, A., Hellevik, C. C., Alaliyat, S. A.-A., Hameed, I. A., Pedrini, H., and da S. Torres, R. (2022). Litter detection with deep learning: A comparative study. *Sensors*, 22(2):548.

- Cui, Y., Jia, M., Lin, T.-Y., Song, Y., and Belongie, S. (2019). Class-balanced loss based on effective number of samples. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9268–9277.
- Efron, B. and Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.
- Gupta, A., Dollár, P., and Girshick, R. (2019). LVIS: A dataset for large vocabulary instance segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5356–5364.
- Jocher, G., Qiu, J., Liu, M., Lyu, S., Akyon, F. C., and Kalfaoglu, M. E. (2026). Ultralytics YOLO26: Unified real-time end-to-end vision models.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *European Conference on Computer Vision*, pages 740–755.
- Loshchilov, I. and Hutter, F. (2019). Decoupled weight decay regularization. In *International Conference on Learning Representations*.
- Proença, P. F. and Simões, P. (2020). TACO: Trash annotations in context for litter detection. *CoRR*, abs/2003.06975.
- Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 779–788.