

# O Custo da Granularidade Semântica na Detecção de Resíduos: um Estudo Controlado com TACO e YOLO26n

Nome do(a) Autor(a)<sup>1</sup>

<sup>1</sup>Instituição do(a) Autor(a)

Cidade – Estado – Brasil

email@exemplo.com

**Resumo.** A detecção de resíduos em cenas não controladas combina localização com uma decisão semântica cuja dificuldade depende da taxonomia. Este trabalho quantifica esse custo no TACO usando as mesmas imagens e caixas em três taxonomias: 60 classes detalhadas, seis grupos por material e uma classe para resíduo. Modelos YOLO26n foram treinados sob protocolo idêntico com três sementes e avaliados em teste fixo. O  $AP_{50}$  médio foi  $0,146 \pm 0,022$ ,  $0,183 \pm 0,023$  e  $0,567 \pm 0,002$  para Fine, Material e Binary. Entre modelos treinados separadamente, o bootstrap sustentou a melhora de Material em  $F_1$ , mas a diferença de AP permaneceu inconclusiva em duas sementes. Ao julgar as mesmas detecções Fine com rótulos mais amplos, o  $AP_{50}$  passou de  $0,103 \pm 0,007$  para  $0,171 \pm 0,015$  no nível de material e  $0,466 \pm 0,014$  sem distinção de classe; esses ganhos foram sustentados nas três sementes. No limiar de confiança 0,25,  $56,95 \pm 1,38\%$  dos casamentos espaciais tinham classe Fine incorreta e  $404,7 \pm 10,6$  dos 637 objetos foram omitidos. Classes raras obtiveram AP e revocação inferiores. Os resultados caracterizam a discriminação semântica sob cauda longa como um gargalo importante, coexistente com falhas espaciais; a taxonomia por material constitui um compromisso útil, embora sua superioridade em AP não seja estatisticamente definitiva.

## 1. Introdução

Detectar resíduos em ambientes externos é diferente de reconhecer itens em condições controladas: os objetos podem ser pequenos, deformáveis, transparentes, ocluídos ou visualmente confundidos com o fundo. O TACO (*Trash Annotations in Context*) foi criado para representar esse cenário, reunindo fotografias de ambientes diversos e uma taxonomia hierárquica de resíduos [Proença and Simões 2020b]. Entretanto, sua versão oficial contém apenas 1.500 imagens e 4.784 instâncias distribuídas em 60 categorias, combinação que impõe simultaneamente poucos dados e forte desbalanceamento.

Em detecção multiclasse, uma caixa espacialmente correta é considerada erro quando recebe a classe errada. Assim, o desempenho pode diminuir tanto por falhas de localização quanto pela exigência de distinguir categorias visualmente próximas e pouco representadas. A granularidade da taxonomia determina quanta informação semântica se exige do modelo, mas comparações entre estudos costumam misturar arquiteturas, partições e agrupamentos diferentes. Isso impede atribuir a variação de desempenho apenas aos rótulos.

Este trabalho investiga: *como a granularidade das classes afeta a detecção de resíduos em um conjunto pequeno e de cauda longa, e quanto da perda decorre de localização versus discriminação semântica?* Para isolar essa variável, fixamos imagens, caixas,

partição e protocolo de treino, alterando somente a taxonomia: Fine (60 classes oficiais), Material (seis macroclasses) e Binary (uma classe *Litter*). Empregamos o YOLO26n, variante compacta da família YOLO26 [Jocher et al. 2026], sem modificar sua arquitetura.

As contribuições são: (i) comparação controlada dos três níveis com três sementes; (ii) avaliação hierárquica das *mesmas* predições Fine, remapeadas para material e para classe única; (iii) intervalos de confiança por bootstrap pareado por imagem, repetidos independentemente para cada semente; e (iv) análises multissemente de cauda longa e uma decomposição auditável dos erros. Todo número apresentado é produzido por scripts a partir das anotações, configurações, checkpoints ou predições salvas.

## 2. Trabalhos Relacionados


Proença e Simões [Proença and Simões 2020b] introduziram o TACO com 60 categorias pertencentes a 28 supercategorias. Reconhecendo a ambiguidade visual e o desbalanceamento, os autores avaliaram Mask R-CNN em TACO-1, sem classes, e TACO-10, com nove supercategorias frequentes e uma classe residual. Portanto, agrupamento de rótulos no TACO não é inédito. Nosso recorte difere por estabelecer três níveis ordenados, incluir um nível intermediário por material e reavaliar hierarquicamente as mesmas detecções para separar localização de semântica.

Córdova et al. [Córdova et al. 2022] compararam Faster R-CNN, Mask R-CNN, RetinaNet, EfficientDet e YOLOv5 em TACO e PlastOPol, relatando dificuldades com objetos pequenos e cenários naturais complexos. O estudo mostra a relevância de detectores YOLO leves, mas seus números não são diretamente comparáveis aos nossos: taxonomia, partição, versões dos modelos e protocolo diferem. Aqui o objetivo não é estabelecer estado da arte, e sim medir uma variável experimental.

YOLO surgiu como detector de estágio único orientado a inferência em tempo real [Redmon et al. 2016]. O YOLO26 unifica modelos atuais da Ultralytics e oferece uma cabeça *end-to-end* sem NMS, além de mecanismos de atribuição voltados a objetos pequenos [Jocher et al. 2026]. Seleccionamos a variante nano por compatibilidade com uma GPU de 6 GB; não comparamos arquiteturas.

Em aprendizado visual, *cauda longa* descreve a distribuição de frequência dos rótulos: poucas classes de “cabeça” concentram grande parte das amostras, enquanto muitas classes da “cauda” têm poucos exemplos [Cui et al. 2019]. O termo se refere, portanto, ao desbalanceamento entre classes, não ao tamanho dos objetos nas imagens. Em detecção e segmentação de grande vocabulário, o LVIS mostrou que essa escassez está associada a desempenho inferior nas categorias pouco representadas [Gupta et al. 2019]. Perdas balanceadas por classe são uma linha de mitigação [Cui et al. 2019]; aqui não alteramos amostragem ou função de perda, pois isso adicionaria fatores experimentais. Em vez disso, medimos o desempenho nos estratos raro, médio e frequente.

Diagnósticos de detectores também requerem separar classificação, localização, duplicatas, fundo e omissões. Essa motivação é formalizada pelo TIDE [Bolya et al. 2020]. Nossa decomposição segue categorias análogas, mas emprega um casamento guloso próprio e deve ser interpretada como análise descritiva no limiar escolhido.



**Figura 1. Pipeline experimental.** Somente a taxonomia varia entre os três ramos de treinamento; imagens, caixas, partição, arquitetura e hiperparâmetros permanecem fixos.


### 3. Metodologia

A Figura 1 sintetiza o desenho experimental. A partir de uma única versão auditada do TACO, mantemos a partição e as caixas constantes, derivamos três taxonomias, treinamos cada uma sob protocolo idêntico e aplicamos cinco análises complementares no mesmo conjunto de teste.

#### 3.1. Dados, auditoria e partição

Usamos exclusivamente o arquivo `data/annotations.json`, obtido do repositório oficial TACO [Proença and Simões 2020a]. As anotações seguem o formato COCO [Lin et al. 2014]; neste estudo, usamos somente *bounding boxes*. A auditoria programática confirmou 1.500 imagens, 4.784 objetos, 60 categorias, nenhuma imagem vazia e nenhum arquivo ausente. Sete caixas excediam a borda em no máximo 1,32 pixel; elas foram recortadas apenas na conversão, mantendo o JSON oficial intacto e registrando cada alteração.

A partição foi sorteada uma vez por imagem com semente 42: treino, validação e teste receberam, respectivamente, 1.050/225/225 imagens e 3.359/788/637 objetos. As três taxonomias reutilizam exatamente essa partição. As coordenadas COCO  $(x, y, w, h)$  foram convertidas para centro, largura e altura normalizados do YOLO; scripts verificaram limites, dimensões positivas, IDs e igualdade das partições. Imagens com orientação EXIF foram transpostas fisicamente antes da conversão.



**Figura 2.** Instâncias de treino das 60 classes Fine, ordenadas por frequência. As linhas marcam os limiares da análise de cauda longa.

### 3.2. Taxonomias

Fine preserva as 60 categorias oficiais. Material remapeia todas elas para Plastic (24 categorias de origem), Metal (9), Glass (4), Paper/Cardboard (13), Organic (1) e Other (9). Compostos ou itens sem associação natural, como bateria, sapato e embalagens multi-camadas, foram enviados a Other; cada decisão e sua justificativa estão em `configs/material_mapping.json`. Binary atribui *Litter* a todas as instâncias. As caixas não mudam entre versões. A Figura 2 evidencia a cauda longa que motiva os agrupamentos.

### 3.3. Modelo e protocolo experimental

Treinaamos YOLO26n inicializado com pesos COCO, entrada  $640 \times 640$ , lote 24, até 60 épocas, *early stopping* com paciência 15, AdamW [Loshchilov and Hutter 2019] e taxa inicial  $10^{-3}$ . Foram mantidas as transformações padrão da implementação Ultralytics, precisão mista e determinismo. Todos os experimentos usaram Python 3.12.10, PyTorch 2.8.0+cu128 e Ultralytics 8.4.157 em uma RTX 3060 Laptop de 6 GB. As sementes 42, 123 e 2026 foram aplicadas às três taxonomias; não houve ajuste específico por configuração.

### 3.4. Avaliação e incerteza

No teste fixo, reportamos precisão, revocação,  $F_1$ ,  $AP_{50}$  e  $AP_{50:95}$  da implementação Ultralytics; esta última média usa IoU de 0,50 a 0,95 em passos de 0,05. A Tabela principal apresenta média e desvio-padrão entre sementes.

Para uma caixa predita  $B$  e uma verdade-terreno  $G$ , definimos a sobreposição por

$$\text{IoU}(B, G) = \frac{|B \cap G|}{|B \cup G|}. \quad (1)$$

Em cada limiar  $\tau$ , o AP é a média da precisão interpolada em 101 níveis de recall. A métrica mais estrita agrega dez limiares:

$$AP_{50:95} = \frac{1}{10} \sum_{k=0}^9 AP_{0,50+0,05k}. \quad (2)$$

O  $F_1 = 2PR/(P + R)$  resume precisão e revocação no ponto operacional selecionado pelo avaliador.

Para decompor o erro, um avaliador controlado faz casamento guloso um-para-um em ordem decrescente de confiança. Seja  $\pi_L : \mathcal{C}_{Fine} \rightarrow \mathcal{C}_L$  o mapeamento para o nível  $L \in \{Fine, Material, Binary\}$ . Cada detecção  $(B_i, c_i, s_i)$  é reavaliada como

$$(B_i, c_i, s_i) \mapsto (B_i, \pi_L(c_i), s_i), \quad (3)$$

preservando geometria e confiança. Como o número de classes e a macro-média também mudam, o ganho hierárquico combina o crédito recuperado por confusões colapsadas com o efeito da agregação de categorias. Esta implementação não é numericamente idêntica ao avaliador nativo; seus valores são comparados apenas entre si.

Aplicamos bootstrap percentil pareado [Efron and Tibshirani 1993] para obter ICs de 95%. Em cada réplica  $b$ , reamostramos com reposição as 225 imagens e calculamos

$$\Delta^{(b)} = M_A(\mathcal{I}^{(b)}) - M_B(\mathcal{I}^{(b)}), \quad IC_{95\%} = [Q_{0,025}(\Delta), Q_{0,975}(\Delta)]. \quad (4)$$

Fizemos 2.000 reamostragens para cada uma das três sementes, com os mesmos índices nos dois lados de cada comparação. Reportamos a média e o desvio-padrão das diferenças médias do bootstrap entre sementes. Para tornar a leitura uniforme, orientamos as diferenças de modo que valores positivos sempre favoreçam a taxonomia mais simples; também contamos em quantas sementes o IC exclui zero. O cálculo foi acelerado pré-computando os casamentos por classe e limiar de IoU; testes automatizados confirmaram equivalência numérica com o avaliador original a  $10^{-12}$ . Para a análise de cauda longa,  $n$  é o número de instâncias de treino por classe: rara ( $n \leq 19$ ), média ( $20 \leq n \leq 100$ ) e frequente ( $n > 100$ ). Esses cortes são estratos operacionais deste estudo, não uma definição universal de cauda longa. Métricas por classe incluem somente rótulos presentes no teste fixo.

## 4. Resultados

### 4.1. Efeito da taxonomia

A Tabela 1 resume os modelos treinados. Material elevou o  $AP_{50}$  médio de 0,146 para 0,183 e o  $F_1$  de 0,232 para 0,296 em relação a Fine. Binary alcançou 0,567 de  $AP_{50}$  e apresentou a menor variação entre sementes ( $\sigma = 0,002$ ). Esse ganho não constitui uma comparação de capacidade semântica equivalente: Binary só precisa separar resíduo de fundo.

**Tabela 1. Teste por taxonomia: média  $\pm$  desvio-padrão de três sementes.**

| Taxonomia | $P$               | $R$               | $F_1$             | $AP_{50}$         | $AP_{50:95}$      |
|-----------|-------------------|-------------------|-------------------|-------------------|-------------------|
| Fine      | 0.360 $\pm$ 0.063 | 0.173 $\pm$ 0.010 | 0.232 $\pm$ 0.005 | 0.146 $\pm$ 0.022 | 0.118 $\pm$ 0.022 |
| Material  | 0.387 $\pm$ 0.050 | 0.241 $\pm$ 0.012 | 0.296 $\pm$ 0.006 | 0.183 $\pm$ 0.023 | 0.131 $\pm$ 0.023 |
| Binary    | 0.750 $\pm$ 0.050 | 0.491 $\pm$ 0.018 | 0.593 $\pm$ 0.004 | 0.567 $\pm$ 0.002 | 0.405 $\pm$ 0.005 |

O bootstrap separa média superior de evidência repetível. Embora Material tenha superado Fine em média nas três métricas, seus ganhos de AP tiveram IC95% acima de zero em apenas uma das três sementes. O ganho de  $F_1$ , por outro lado, foi sustentado nas três. Portanto, os modelos treinados separadamente permitem afirmar uma melhora consistente em  $F_1$ , mas não uma superioridade inequívoca de AP.

## 4.2. Localização versus semântica

A Tabela 2 responde a uma pergunta diferente: o que acontece quando as *mesmas* caixas e confianças produzidas pelo modelo Fine são julgadas com menos detalhe semântico? Ao aceitar a macroclasse de material,  $AP_{50}$  passou de 0,103 para 0,171; ao ignorar classes, chegou a 0,466. Como não há novo treinamento nesta análise, o ganho mostra quanto da penalização depende dos rótulos, embora a mudança da macro-média impeça interpretá-lo como contagem pura de erros semânticos. A Tabela 3 informa se esse efeito se repete entre sementes.


**Tabela 2. Mesmas predições Fine avaliadas em três níveis pelo avaliador controlado (média  $\pm$  desvio-padrão).**

| Nível de avaliação | $F_1$             | $AP_{50}$         | $AP_{50:95}$      |
|--------------------|-------------------|-------------------|-------------------|
| Fine               | $0.168 \pm 0.016$ | $0.103 \pm 0.007$ | $0.082 \pm 0.005$ |
| Material           | $0.264 \pm 0.021$ | $0.171 \pm 0.015$ | $0.122 \pm 0.010$ |
| Binary             | $0.506 \pm 0.011$ | $0.466 \pm 0.014$ | $0.322 \pm 0.011$ |

**Tabela 3. Síntese do bootstrap pareado nas três sementes.**

| Comparação                  | $AP_{50}$                | $AP_{50:95}$             | $F_1$                    |
|-----------------------------|--------------------------|--------------------------|--------------------------|
| Material treinado vs. Fine  | $+0,051 \pm 0,022$ (1/3) | $+0,029 \pm 0,023$ (1/3) | $+0,074 \pm 0,027$ (3/3) |
| Fine como Material vs. Fine | $+0,068 \pm 0,012$ (3/3) | $+0,039 \pm 0,010$ (2/3) | $+0,101 \pm 0,008$ (3/3) |
| Fine como Binary vs. Fine   | $+0,345 \pm 0,016$ (3/3) | $+0,226 \pm 0,012$ (3/3) | $+0,318 \pm 0,011$ (3/3) |


Cada célula da Tabela 3 apresenta ganho médio  $\pm$  desvio-padrão e, entre parênteses, quantos ICs de 95% excluem zero. Valores positivos favorecem a alternativa mais simples; 3/3 indica evidência repetida nas três sementes, enquanto 1/3 recomenda cautela. “Fine como” denota remapeamento das mesmas predições, sem novo treinamento.



**Figura 3. À esquerda, modelos treinados separadamente e avaliados pelo Ultralytics; à direita, mesmas predições Fine remapeadas e avaliadas pelo protocolo controlado. Barras de erro: um desvio-padrão entre sementes.**

### 4.3. Exemplos nos níveis Material e Binary

A Figura 4 amplia a análise visual para os outros modelos. Em (a), o modelo Material localiza e classifica corretamente um filme plástico. Os painéis (b) e (c) usam a mesma garrafa: o modelo Material preserva a localização, mas prevê Paper/Cardboard em vez de Plastic, enquanto o modelo Binary a reconhece como *Litter*. Esse par mostra, em uma entrada controlada, como remover a exigência de material pode recuperar um acerto. O painel (d) estabelece o limite dessa simplificação: mesmo sem precisar distinguir materiais, o modelo Binary omite um pneu grande no limiar de confiança 0,25. Logo, reduzir a taxonomia elimina certos erros semânticos, mas não garante cobertura espacial.



**Figura 4. Predições reais dos modelos Material e Binary, semente 42. Os painéis (b) e (c) mostram a mesma imagem sob duas taxonomias; (d) mostra uma omissão binária.**

### 4.4. Cauda longa e tipos de erro

A Tabela 4 mostra crescimento monotônico com a frequência. Entre as classes presentes no teste, as raras obtiveram  $AP_{50} = 0,046$  e recall 0,053, enquanto as frequentes atingiram 0,207 e 0,282. Logo, a dificuldade Fine não se distribui uniformemente entre rótulos.

**Tabela 4. Desempenho Fine por frequência no treino, agregado em três sementes; somente classes com suporte no teste.**

| Grupo      | #classes | $n_{treino}$ | AP <sub>50</sub> | Recall      |
|------------|----------|--------------|------------------|-------------|
| Raras      | 16       | 6.1          | 0.046±0.009      | 0.053±0.012 |
| Médias     | 22       | 43.9         | 0.098±0.022      | 0.198±0.049 |
| Frequentes | 10       | 225.1        | 0.207±0.017      | 0.282±0.019 |

Como diagnóstico adicional, no limiar de confiança 0,25, as três sementes produziram  $100,0 \pm 5,2$  acertos Fine e  $132,3 \pm 7,2$  confusões semânticas entre  $232,3 \pm 10,6$  casamentos espaciais. Portanto,  $56,95 \pm 1,38\%$  dos casamentos em  $\text{IoU} \geq 0,5$  tinham classe Fine incorreta. Em média, houve ainda  $16,3 \pm 5,5$  falhas de localização ( $0,1 \leq \text{IoU} < 0,5$ ),  $40,7 \pm 8,1$  duplicatas,  $47,3 \pm 5,0$  falsos positivos de fundo ( $\text{IoU} < 0,1$ ) e  $404,7 \pm 10,6$  objetos omitidos. Estes correspondem a  $63,5 \pm 1,7\%$  dos 637 objetos de teste. Os totais dependem do limiar e servem para caracterização, não como substitutos das curvas de AP [Bolya et al. 2020].

**Tabela 5. Decomposição dos erros Fine por semente no limiar de confiança 0,25. Categorias de predição e omissões são mutuamente exclusivas dentro de seus respectivos inventários.**


| Categoria                | 42  | 123 | 2026 | Média ± DP       |
|--------------------------|-----|-----|------|------------------|
| Acerto Fine              | 97  | 106 | 97   | $100,0 \pm 5,2$  |
| Confusão no material     | 51  | 57  | 52   | $53,3 \pm 3,2$   |
| Confusão entre materiais | 73  | 79  | 85   | $79,0 \pm 6,0$   |
| Falha de localização     | 11  | 16  | 22   | $16,3 \pm 5,5$   |
| Duplicata                | 32  | 42  | 48   | $40,7 \pm 8,1$   |
| Falso positivo de fundo  | 42  | 48  | 52   | $47,3 \pm 5,0$   |
| Objeto omitido           | 416 | 395 | 403  | $404,7 \pm 10,6$ |

A Figura 5 liga essa decomposição às imagens de teste. A primeira linha apresenta o mesmo recorte sem anotações, com a verdade-terreno e com uma saída correta. Na segunda, uma lata é localizada corretamente, mas confundida com aerossol, preservando o material; uma embalagem metálica é confundida com papel/cartão; e uma tampa plástica anotada não recebe predição. Os exemplos tornam visíveis erros semânticos e espaciais de naturezas distintas.

## 5. Discussão

A divergência entre  $F_1$  e AP é informativa. O primeiro descreve um ponto operacional de precisão e revocação, enquanto AP resume o ranqueamento ao longo de diferentes níveis de confiança. Material mostrou vantagem mais confiável no ponto operacional, mas os dados não bastam para declará-lo um detector globalmente superior a Fine. Binary, por sua vez, resolve uma tarefa operacionalmente mais simples e não informa a composição do resíduo; sua métrica mais alta deve ser lida junto dessa perda de informação.

A avaliação hierárquica e a decomposição de erros cumprem papéis complementares. A primeira mantém geometria e confiança fixas, isolando o efeito de exigir rótulos



**Figura 5. Casos reais do teste Fine, semente 42. A primeira linha separa entrada, anotação e saída correta; a segunda exemplifica confusão intra-material, confusão inter-material e omissão. As imagens foram recortadas apenas para legibilidade; a prevalência de cada erro é quantificada nas três sementes na Tabela 5.**

mais específicos; a segunda impede atribuir todo ganho agregado à classificação, pois conta separadamente confusões, localização, duplicatas, fundo e omissões. A estabilidade dessas categorias entre sementes reduz a chance de o diagnóstico ser um acaso de otimização. Ainda assim, omissões são o erro mais numeroso: simplificar a taxonomia remove parte da penalização semântica, mas não resolve a cobertura espacial.

A cauda longa oferece uma explicação complementar. Das 28 classes raras definidas pelo treino, apenas 16 aparecem no teste; essas 16 têm, em média, 6,1 instâncias de treino e desempenho muito inferior às dez frequentes. Isso é consistente com a literatura de detecção de grande vocabulário [Gupta et al. 2019], mas aqui não demonstra causalidade isolada: tamanho, oclusão, contexto e semelhança visual também variam entre classes. A macroclasse Material compartilha dados entre rótulos relacionados e preserva uma informação potencialmente útil à triagem, constituindo compromisso plausível entre especificidade e robustez.

Há quatro ameaças principais à validade. Primeiro, uma única partição fixa não mede variação de amostragem; as três sementes medem somente a instabilidade de otimização. Segundo, embora repetido para cada modelo Fine, o bootstrap condiciona-se às mesmas 225 imagens de teste e não substitui novas partições ou dados externos. Terceiro, o mapeamento por material é uma decisão de projeto: compostos foram enviados a Other, e Organic contém apenas *Food waste*. Quarto, não comparamos diretamente nossos números aos de trabalhos anteriores devido a diferenças de tarefa e protocolo. Estudos futuros de-

vem repetir partições, avaliar agrupamentos alternativos e testar técnicas de balanceamento sem alterar simultaneamente outros componentes.

## 6. Conclusão

Este estudo responde que a granularidade semântica impõe um custo mensurável à detecção no TACO, mas não é seu único gargalo. Material oferece um compromisso defensável: preserva informação útil sobre composição e melhora o ponto operacional frente a Fine, embora sua superioridade em AP não seja uniforme. Binary maximiza a detectabilidade ao custo de eliminar essa informação. A avaliação das mesmas caixas, a decomposição de erros e a cauda longa mostram, em conjunto, que confusão semântica, escassez de exemplos e omissões espaciais coexistem. Portanto, a taxonomia deve ser escolhida pela informação exigida pela aplicação, e não apenas pela maior métrica. A pipeline disponibiliza configurações, mapeamento integral, partição, previsões, scripts e artefatos derivados para reprodução e extensão do estudo.

## Referências

- Bolya, D., Foley, S., Hays, J., and Hoffman, J. (2020). TIDE: A general toolbox for identifying object detection errors. In *European Conference on Computer Vision*, pages 558–573.
- Córdova, M., Pinto, A., Hellevik, C. C., Alaliyat, S. A.-A., Hameed, I. A., Pedrini, H., and da S. Torres, R. (2022). Litter detection with deep learning: A comparative study. *Sensors*, 22(2):548.
- Cui, Y., Jia, M., Lin, T.-Y., Song, Y., and Belongie, S. (2019). Class-balanced loss based on effective number of samples. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9268–9277.
- Efron, B. and Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.
- Gupta, A., Dollár, P., and Girshick, R. (2019). LVIS: A dataset for large vocabulary instance segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5356–5364.
- Jocher, G., Qiu, J., Liu, M., Lyu, S., Akyon, F. C., and Kalfaoglu, M. E. (2026). Ultralytics YOLO26: Unified real-time end-to-end vision models.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *European Conference on Computer Vision*, pages 740–755.
- Loshchilov, I. and Hutter, F. (2019). Decoupled weight decay regularization. In *International Conference on Learning Representations*.
- Proença, P. F. and Simões, P. (2020a). TACO: Trash annotations in context – official repository. GitHub repository. Acessado em 22 set. 2026.
- Proença, P. F. and Simões, P. (2020b). TACO: Trash annotations in context for litter detection. *CoRR*, abs/2003.06975.

Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 779–788.