

O Custo da Granularidade Semântica na Detecção de Resíduos: um Estudo Controlado com TACO e YOLO26n

Jean Carlos Rodrigues Sousa¹, Karielly de Carvalho¹, Marcos¹

¹Universidade Federal do Piauí (UFPI)
Campus Senador Helvídio Nunes de Barros (CSHNB)
Picos – PI – Brasil

Resumo. A detecção de resíduos em cenas não controladas combina localização com uma decisão semântica cuja dificuldade depende da taxonomia. Este trabalho quantifica esse custo no TACO usando as mesmas imagens e caixas em três taxonomias: 60 classes detalhadas, seis grupos por material e uma classe para resíduo. Modelos YOLO26n foram treinados sob protocolo idêntico com três sementes e avaliados em teste fixo. O AP_{50} médio foi $0,146 \pm 0,022$, $0,183 \pm 0,023$ e $0,567 \pm 0,002$ para Fine, Material e Binary. Entre modelos treinados separadamente, o bootstrap sustentou a melhora de Material em F_1 , mas a diferença de AP permaneceu inconclusiva em duas sementes. Ao julgar as mesmas detecções Fine com rótulos mais amplos, o AP_{50} passou de $0,103 \pm 0,007$ para $0,171 \pm 0,015$ no nível de material e $0,466 \pm 0,014$ sem distinção de classe; esses ganhos foram sustentados nas três sementes. No limiar de confiança 0,25, $56,95 \pm 1,38\%$ dos casamentos espaciais tinham classe Fine incorreta e $404,7 \pm 10,6$ dos 637 objetos foram omitidos. Classes raras obtiveram AP e revocação inferiores. Os resultados caracterizam a discriminação semântica sob cauda longa como um gargalo importante, coexistente com falhas espaciais; a taxonomia por material constitui um compromisso útil, embora sua superioridade em AP não seja estatisticamente definitiva.

1. Introdução

Detectar resíduos em ambientes externos é diferente de reconhecer itens em condições controladas: os objetos podem ser pequenos, deformáveis, transparentes, ocluídos ou visualmente confundidos com o fundo. O TACO (*Trash Annotations in Context*) foi criado para representar esse cenário, reunindo fotografias de ambientes diversos e uma taxonomia hierárquica de resíduos [Proença and Simões 2020b]. Entretanto, sua versão oficial contém apenas 1.500 imagens e 4.784 instâncias distribuídas em 60 categorias, combinação que impõe simultaneamente poucos dados e forte desbalanceamento.

Em detecção multiclasse, uma caixa espacialmente correta é considerada erro quando recebe a classe errada. Assim, o desempenho pode diminuir tanto por falhas de localização quanto pela exigência de distinguir categorias visualmente próximas e pouco representadas. A granularidade da taxonomia determina quanta informação semântica se exige do modelo, mas comparações entre estudos costumam misturar arquiteturas, partições e agrupamentos diferentes. Isso impede atribuir a variação de desempenho apenas aos rótulos.

Este trabalho investiga: *como a granularidade das classes afeta a detecção de resíduos em um conjunto pequeno e de cauda longa, e quanto da perda decorre de localização versus discriminação semântica?* Para isolar essa variável, fixamos imagens, caixas,

partição e protocolo de treino, alterando somente a taxonomia: Fine (60 classes oficiais), Material (seis macroclasses) e Binary (uma classe *Litter*). Empregamos o YOLO26n, variante compacta da família YOLO26 [Jocher et al. 2026], sem modificar sua arquitetura.

As contribuições são: (i) comparação controlada dos três níveis com três sementes; (ii) avaliação hierárquica das *mesmas* previsões Fine, remapeadas para material e para classe única; (iii) intervalos de confiança por bootstrap pareado por imagem, repetidos independentemente para cada semente; e (iv) análises multissemente de cauda longa e uma decomposição auditável dos erros. Todo número apresentado é produzido por scripts a partir das anotações, configurações, checkpoints ou previsões salvas.

2. Trabalhos Relacionados

Proença e Simões [Proença and Simões 2020b] introduziram o TACO com 60 categorias pertencentes a 28 supercategorias. Reconhecendo a ambiguidade visual e o desbalanceamento, os autores avaliaram Mask R-CNN em TACO-1, sem classes, e TACO-10, com nove supercategorias frequentes e uma classe residual. Portanto, agrupamento de rótulos no TACO não é inédito. Nosso recorte difere por estabelecer três níveis ordenados, incluir um nível intermediário por material e reavaliar hierarquicamente as mesmas detecções para separar localização de semântica.

Córdova et al. [Córdova et al. 2022] compararam Faster R-CNN, Mask R-CNN, RetinaNet, EfficientDet e YOLOv5 em TACO e PlastOPol, relatando dificuldades com objetos pequenos e cenários naturais complexos. O estudo mostra a relevância de detectores YOLO leves, mas seus números não são diretamente comparáveis aos nossos: taxonomia, partição, versões dos modelos e protocolo diferem. Aqui o objetivo não é estabelecer estado da arte, e sim medir uma variável experimental.

YOLO surgiu como detector de estágio único orientado a inferência em tempo real [Redmon et al. 2016]. O YOLO26 unifica modelos atuais da Ultralytics e oferece uma cabeça *end-to-end* sem NMS, além de mecanismos de atribuição voltados a objetos pequenos [Jocher et al. 2026]. Seleccionamos a variante nano por compatibilidade com uma GPU de 6 GB; não comparamos arquiteturas.

Em aprendizado visual, *cauda longa* descreve a distribuição de frequência dos rótulos: poucas classes de “cabeça” concentram grande parte das amostras, enquanto muitas classes da “cauda” têm poucos exemplos [Cui et al. 2019]. O termo se refere, portanto, ao desbalanceamento entre classes, não ao tamanho dos objetos nas imagens. Em detecção e segmentação de grande vocabulário, o LVIS mostrou que essa escassez está associada a desempenho inferior nas categorias pouco representadas [Gupta et al. 2019]. Perdas balanceadas por classe são uma linha de mitigação [Cui et al. 2019]; aqui não alteramos amostragem ou função de perda, pois isso adicionaria fatores experimentais. Em vez disso, medimos o desempenho nos estratos raro, médio e frequente.

Diagnósticos de detectores também requerem separar classificação, localização, duplicatas, fundo e omissões. Essa motivação é formalizada pelo TIDE [Bolya et al. 2020]. Nossa decomposição segue categorias análogas, mas emprega um casamento guloso próprio e deve ser interpretada como análise descritiva no limiar escolhido.




Figura 1. Pipeline experimental. Somente a taxonomia varia entre os três ramos de treinamento; imagens, caixas, partição, arquitetura e hiperparâmetros permanecem fixos.

3. Metodologia

A Figura 1 sintetiza o desenho experimental. A partir de uma única versão auditada do TACO, mantemos a partição e as caixas constantes, derivamos três taxonomias, treinamos cada uma sob protocolo idêntico e aplicamos cinco análises complementares no mesmo conjunto de teste.

3.1. Dados, auditoria e partição

Usamos exclusivamente o arquivo `data/annotations.json`, obtido do repositório oficial TACO [Proença and Simões 2020a]. As anotações seguem o formato COCO [Lin et al. 2014]; neste estudo, usamos somente *bounding boxes*. A auditoria programática confirmou 1.500 imagens, 4.784 objetos, 60 categorias, nenhuma imagem vazia e nenhum arquivo ausente. Sete caixas excediam a borda em no máximo 1,32 pixel; elas foram recortadas apenas na conversão, mantendo o JSON oficial intacto e registrando cada alteração.

A partição foi sorteada uma vez por imagem com semente 42: treino, validação e teste receberam, respectivamente, 1.050/225/225 imagens e 3.359/788/637 objetos. As três taxonomias reutilizam exatamente essa partição. As coordenadas COCO (x, y, w, h) foram convertidas para centro, largura e altura normalizados do YOLO; scripts verificaram limites, dimensões positivas, IDs e igualdade das partições. Imagens com orientação EXIF foram transpostas fisicamente antes da conversão.




Figura 2. Instâncias de treino das 60 classes Fine, ordenadas por frequência. As linhas marcam os limiares da análise de cauda longa.

3.2. Taxonomias

Fine preserva as 60 categorias oficiais. Material remapeia todas elas para Plastic (24 categorias de origem), Metal (9), Glass (4), Paper/Cardboard (13), Organic (1) e Other (9). Compostos ou itens sem associação natural, como bateria, sapato e embalagens multi-camadas, foram enviados a Other; cada decisão e sua justificativa estão em `configs/material_mapping.json`. Binary atribui *Litter* a todas as instâncias. As caixas não mudam entre versões. A Figura 2 evidencia a cauda longa que motiva os agrupamentos.

3.3. Modelo e protocolo experimental

Treinaamos YOLO26n inicializado com pesos COCO, entrada 640×640 , lote 24, até 60 épocas, *early stopping* com paciência 15, AdamW [Loshchilov and Hutter 2019] e taxa inicial 10^{-3} . Foram mantidas as transformações padrão da implementação Ultralytics, precisão mista e determinismo. Todos os experimentos usaram Python 3.12.10, PyTorch 2.8.0+cu128 e Ultralytics 8.4.157 em uma RTX 3060 Laptop de 6 GB. As sementes 42, 123 e 2026 foram aplicadas às três taxonomias; não houve ajuste específico por configuração.

3.4. Avaliação e incerteza

No teste fixo, reportamos precisão, revocação, F_1 , AP_{50} e $AP_{50:95}$ da implementação Ultralytics; esta última média usa IoU de 0,50 a 0,95 em passos de 0,05. A Tabela principal apresenta média e desvio-padrão entre sementes.

Para uma caixa predita B e uma verdade-terreno G , definimos a sobreposição por

$$\text{IoU}(B, G) = \frac{|B \cap G|}{|B \cup G|}. \quad (1)$$

Em cada limiar τ , o AP é a média da precisão interpolada em 101 níveis de recall. A métrica mais estrita agrega dez limiares:

$$AP_{50:95} = \frac{1}{10} \sum_{k=0}^9 AP_{0,50+0,05k}. \quad (2)$$

O $F_1 = 2PR/(P + R)$ resume precisão e revocação no ponto operacional selecionado pelo avaliador.

Para decompor o erro, um avaliador controlado faz casamento guloso um-para-um em ordem decrescente de confiança. Seja $\pi_L : \mathcal{C}_{Fine} \rightarrow \mathcal{C}_L$ o mapeamento para o nível $L \in \{Fine, Material, Binary\}$. Cada detecção (B_i, c_i, s_i) é reavaliada como

$$(B_i, c_i, s_i) \mapsto (B_i, \pi_L(c_i), s_i), \quad (3)$$

preservando geometria e confiança. Como o número de classes e a macro-média também mudam, o ganho hierárquico combina o crédito recuperado por confusões colapsadas com o efeito da agregação de categorias. Esta implementação não é numericamente idêntica ao avaliador nativo; seus valores são comparados apenas entre si.

Aplicamos bootstrap percentil pareado [Efron and Tibshirani 1993] para obter ICs de 95%. Em cada réplica b , reamostramos com reposição as 225 imagens e calculamos

$$\Delta^{(b)} = M_A(\mathcal{I}^{(b)}) - M_B(\mathcal{I}^{(b)}), \quad IC_{95\%} = [Q_{0,025}(\Delta), Q_{0,975}(\Delta)]. \quad (4)$$

Fizemos 2.000 reamostragens para cada uma das três sementes, com os mesmos índices nos dois lados de cada comparação. Reportamos a média e o desvio-padrão das diferenças médias do bootstrap entre sementes. Para tornar a leitura uniforme, orientamos as diferenças de modo que valores positivos sempre favoreçam a taxonomia mais simples; também contamos em quantas sementes o IC exclui zero. O cálculo foi acelerado pré-computando os casamentos por classe e limiar de IoU; testes automatizados confirmaram equivalência numérica com o avaliador original a 10^{-12} . Para a análise de cauda longa, n é o número de instâncias de treino por classe: rara ($n \leq 19$), média ($20 \leq n \leq 100$) e frequente ($n > 100$). Esses cortes são estratos operacionais deste estudo, não uma definição universal de cauda longa. Métricas por classe incluem somente rótulos presentes no teste fixo.

4. Resultados

4.1. Efeito da taxonomia

A Tabela 1 resume os modelos treinados. Material elevou o AP_{50} médio de 0,146 para 0,183 e o F_1 de 0,232 para 0,296 em relação a Fine. Binary alcançou 0,567 de AP_{50} e apresentou a menor variação entre sementes ($\sigma = 0,002$). Esse ganho não constitui uma comparação de capacidade semântica equivalente: Binary só precisa separar resíduo de fundo.

Tabela 1. Teste por taxonomia: média $\pm$ desvio-padrão de três sementes.

Taxonomia	P	R	F_1	AP_{50}	$AP_{50:95}$
Fine	0.360 $\pm$ 0.063	0.173 $\pm$ 0.010	0.232 $\pm$ 0.005	0.146 $\pm$ 0.022	0.118 $\pm$ 0.022
Material	0.387 $\pm$ 0.050	0.241 $\pm$ 0.012	0.296 $\pm$ 0.006	0.183 $\pm$ 0.023	0.131 $\pm$ 0.023
Binary	0.750 $\pm$ 0.050	0.491 $\pm$ 0.018	0.593 $\pm$ 0.004	0.567 $\pm$ 0.002	0.405 $\pm$ 0.005

O bootstrap separa média superior de evidência repetível. Embora Material tenha superado Fine em média nas três métricas, seus ganhos de AP tiveram IC95% acima de zero em apenas uma das três sementes. O ganho de F_1 , por outro lado, foi sustentado nas três. Portanto, os modelos treinados separadamente permitem afirmar uma melhora consistente em F_1 , mas não uma superioridade inequívoca de AP.

4.2. Localização versus semântica

A Tabela 2 responde a uma pergunta diferente: o que acontece quando as *mesmas* caixas e confianças produzidas pelo modelo Fine são julgadas com menos detalhe semântico? Ao aceitar a macroclasse de material, AP_{50} passou de 0,103 para 0,171; ao ignorar classes, chegou a 0,466. Como não há novo treinamento nesta análise, o ganho mostra quanto da penalização depende dos rótulos, embora a mudança da macro-média impeça interpretá-lo como contagem pura de erros semânticos. A Tabela 3 informa se esse efeito se repete entre sementes.

Tabela 2. Mesmas previsões Fine avaliadas em três níveis pelo avaliador controlado (média $\pm$ desvio-padrão).

Nível de avaliação	F_1	AP_{50}	$AP_{50:95}$
Fine	0.168 ± 0.016	0.103 ± 0.007	0.082 ± 0.005
Material	0.264 ± 0.021	0.171 ± 0.015	0.122 ± 0.010
Binary	0.506 ± 0.011	0.466 ± 0.014	0.322 ± 0.011

Tabela 3. Síntese do bootstrap pareado nas três sementes.

Comparação	AP_{50}	$AP_{50:95}$	F_1
Material treinado vs. Fine	$+0,051 \pm 0,022$ (1/3)	$+0,029 \pm 0,023$ (1/3)	$+0,074 \pm 0,027$ (3/3)
Fine como Material vs. Fine	$+0,068 \pm 0,012$ (3/3)	$+0,039 \pm 0,010$ (2/3)	$+0,101 \pm 0,008$ (3/3)
Fine como Binary vs. Fine	$+0,345 \pm 0,016$ (3/3)	$+0,226 \pm 0,012$ (3/3)	$+0,318 \pm 0,011$ (3/3)

Cada célula da Tabela 3 apresenta ganho médio $\pm$ desvio-padrão e, entre parênteses, quantos ICs de 95% excluem zero. Valores positivos favorecem a alternativa mais simples; 3/3 indica evidência repetida nas três sementes, enquanto 1/3 recomenda cautela. “Fine como” denota remapeamento das mesmas previsões, sem novo treinamento.




Figura 3. À esquerda, modelos treinados separadamente e avaliados pelo Ultralytics; à direita, mesmas previsões Fine remapeadas e avaliadas pelo protocolo controlado. Barras de erro: um desvio-padrão entre sementes.

4.3. Exemplos nos níveis Material e Binary

A Figura 4 amplia a análise visual para os outros modelos. Em (a), o modelo Material localiza e classifica corretamente um filme plástico. Os painéis (b) e (c) usam a mesma garrafa: o modelo Material preserva a localização, mas prevê Paper/Cardboard em vez de Plastic, enquanto o modelo Binary a reconhece como *Litter*. Esse par mostra, em uma entrada controlada, como remover a exigência de material pode recuperar um acerto. O painel (d) estabelece o limite dessa simplificação: mesmo sem precisar distinguir materiais, o modelo Binary omite um pneu grande no limiar de confiança 0,25. Logo, reduzir a taxonomia elimina certos erros semânticos, mas não garante cobertura espacial.




Figura 4. Predições reais dos modelos Material e Binary, semente 42. Os painéis (b) e (c) mostram a mesma imagem sob duas taxonomias; (d) mostra uma omissão binária.

4.4. Cauda longa e tipos de erro

A Tabela 4 mostra crescimento monotônico com a frequência. Entre as classes presentes no teste, as raras obtiveram $AP_{50} = 0,046$ e recall 0,053, enquanto as frequentes atingiram 0,207 e 0,282. Logo, a dificuldade Fine não se distribui uniformemente entre rótulos.

Tabela 4. Desempenho Fine por frequência no treino, agregado em três sementes; somente classes com suporte no teste.

Grupo	#classes	n_{treino}	AP_{50}	Recall
Raras	16	6.1	0.046 ± 0.009	0.053 ± 0.012
Médias	22	43.9	0.098 ± 0.022	0.198 ± 0.049
Frequentes	10	225.1	0.207 ± 0.017	0.282 ± 0.019

Como diagnóstico adicional, no limiar de confiança 0,25, as três sementes produziram $100,0 \pm 5,2$ acertos Fine e $132,3 \pm 7,2$ confusões semânticas entre $232,3 \pm 10,6$ casamentos espaciais. Portanto, $56,95 \pm 1,38\%$ dos casamentos em $IoU \geq 0,5$ tinham classe Fine incorreta. Em média, houve ainda $16,3 \pm 5,5$ falhas de localização ($0,1 \leq IoU < 0,5$), $40,7 \pm 8,1$ duplicatas, $47,3 \pm 5,0$ falsos positivos de fundo ($IoU < 0,1$) e $404,7 \pm 10,6$ objetos omitidos. Estes correspondem a $63,5 \pm 1,7\%$ dos 637 objetos de teste. Os totais dependem do limiar e servem para caracterização, não como substitutos das curvas de AP [Bolya et al. 2020].

Tabela 5. Decomposição dos erros Fine por semente no limiar de confiança 0,25. Categorias de predição e omissões são mutuamente exclusivas dentro de seus respectivos inventários.

Categoria	42	123	2026	Média $\pm$ DP
Acerto Fine	97	106	97	$100,0 \pm 5,2$
Confusão no material	51	57	52	$53,3 \pm 3,2$
Confusão entre materiais	73	79	85	$79,0 \pm 6,0$
Falha de localização	11	16	22	$16,3 \pm 5,5$
Duplicata	32	42	48	$40,7 \pm 8,1$
Falso positivo de fundo	42	48	52	$47,3 \pm 5,0$
Objeto omitido	416	395	403	$404,7 \pm 10,6$

A Figura 5 liga essa decomposição às imagens de teste. A primeira linha apresenta o mesmo recorte sem anotações, com a verdade-terreno e com uma saída correta. Na segunda, uma lata é localizada corretamente, mas confundida com aerossol, preservando o material; uma embalagem metálica é confundida com papel/cartão; e uma tampa plástica anotada não recebe predição. Os exemplos tornam visíveis erros semânticos e espaciais de naturezas distintas.

5. Discussão

A divergência entre F_1 e AP é informativa. O primeiro descreve um ponto operacional de precisão e revocação, enquanto AP resume o ranqueamento ao longo de diferentes níveis de confiança. Material mostrou vantagem mais confiável no ponto operacional, mas os dados não bastam para declará-lo um detector globalmente superior a Fine. Binary, por sua vez, resolve uma tarefa operacionalmente mais simples e não informa a composição do resíduo; sua métrica mais alta deve ser lida junto dessa perda de informação.

A avaliação hierárquica e a decomposição de erros cumprem papéis complementares. A primeira mantém geometria e confiança fixas, isolando o efeito de exigir rótulos




Figura 5. Casos reais do teste Fine, semente 42. A primeira linha separa entrada, anotação e saída correta; a segunda exemplifica confusão intra-material, confusão inter-material e omissão. As imagens foram recortadas apenas para legibilidade; a prevalência de cada erro é quantificada nas três sementes na Tabela 5.

mais específicos; a segunda impede atribuir todo ganho agregado à classificação, pois conta separadamente confusões, localização, duplicatas, fundo e omissões. A estabilidade dessas categorias entre sementes reduz a chance de o diagnóstico ser um acaso de otimização. Ainda assim, omissões são o erro mais numeroso: simplificar a taxonomia remove parte da penalização semântica, mas não resolve a cobertura espacial.

A cauda longa oferece uma explicação complementar. Das 28 classes raras definidas pelo treino, apenas 16 aparecem no teste; essas 16 têm, em média, 6,1 instâncias de treino e desempenho muito inferior às dez frequentes. Isso é consistente com a literatura de detecção de grande vocabulário [Gupta et al. 2019], mas aqui não demonstra causalidade isolada: tamanho, oclusão, contexto e semelhança visual também variam entre classes. A macroclasse Material compartilha dados entre rótulos relacionados e preserva uma informação potencialmente útil à triagem, constituindo compromisso plausível entre especificidade e robustez.

Há quatro ameaças principais à validade. Primeiro, uma única partição fixa não mede variação de amostragem; as três sementes medem somente a instabilidade de otimização. Segundo, embora repetido para cada modelo Fine, o bootstrap condiciona-se às mesmas 225 imagens de teste e não substitui novas partições ou dados externos. Terceiro, o mapeamento por material é uma decisão de projeto: compostos foram enviados a Other, e Organic contém apenas *Food waste*. Quarto, não comparamos diretamente nossos números aos de trabalhos anteriores devido a diferenças de tarefa e protocolo. Estudos futuros de-

vem repetir partições, avaliar agrupamentos alternativos e testar técnicas de balanceamento sem alterar simultaneamente outros componentes.

6. Conclusão

Este estudo responde que a granularidade semântica impõe um custo mensurável à detecção no TACO, mas não é seu único gargalo. Material oferece um compromisso defensável: preserva informação útil sobre composição e melhora o ponto operacional frente a Fine, embora sua superioridade em AP não seja uniforme. Binary maximiza a detectabilidade ao custo de eliminar essa informação. A avaliação das mesmas caixas, a decomposição de erros e a cauda longa mostram, em conjunto, que confusão semântica, escassez de exemplos e omissões espaciais coexistem. Portanto, a taxonomia deve ser escolhida pela informação exigida pela aplicação, e não apenas pela maior métrica. A pipeline disponibiliza configurações, mapeamento integral, partição, previsões, scripts e artefatos derivados para reprodução e extensão do estudo.

Referências

- Bolya, D., Foley, S., Hays, J., and Hoffman, J. (2020). TIDE: A general toolbox for identifying object detection errors. In *European Conference on Computer Vision*, pages 558–573.
- Córdova, M., Pinto, A., Hellevik, C. C., Alaliyat, S. A.-A., Hameed, I. A., Pedrini, H., and da S. Torres, R. (2022). Litter detection with deep learning: A comparative study. *Sensors*, 22(2):548.
- Cui, Y., Jia, M., Lin, T.-Y., Song, Y., and Belongie, S. (2019). Class-balanced loss based on effective number of samples. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9268–9277.
- Efron, B. and Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall, New York.
- Gupta, A., Dollár, P., and Girshick, R. (2019). LVIS: A dataset for large vocabulary instance segmentation. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5356–5364.
- Jocher, G., Qiu, J., Liu, M., Lyu, S., Akyon, F. C., and Kalfaoglu, M. E. (2026). Ultralytics YOLO26: Unified real-time end-to-end vision models.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., and Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. In *European Conference on Computer Vision*, pages 740–755.
- Loshchilov, I. and Hutter, F. (2019). Decoupled weight decay regularization. In *International Conference on Learning Representations*.
- Proença, P. F. and Simões, P. (2020a). TACO: Trash annotations in context – official repository. GitHub repository. Acessado em 22 set. 2026.
- Proença, P. F. and Simões, P. (2020b). TACO: Trash annotations in context for litter detection. *CoRR*, abs/2003.06975.

Redmon, J., Divvala, S., Girshick, R., and Farhadi, A. (2016). You only look once: Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition*, pages 779–788.