

UNIVERSIDADE FEDERAL DO PIAUÍ

O custo da granularidade semântica na detecção de resíduos

Estudo controlado com TACO e YOLO26n

Jean Carlos Rodrigues Sousa Karielly de Carvalho
Marcos A. G. B. Brito

UFPI – CSHNB, Picos–PI



Pergunta central

Como a granularidade das classes afeta a detecção em um conjunto pequeno e de cauda longa?

Localização

O modelo precisa encontrar o resíduo e delimitar sua posição.

Semântica

A mesma caixa pode ser penalizada quando recebe um rótulo incorreto.

O experimento mantém imagens, caixas, partição e treinamento constantes. Somente a taxonomia muda.

TACO e o problema de cauda longa

1.500


imagens em ambientes
reais

4.784

objetos anotados

60

classes Fine oficiais



Cauda longa

Poucas classes concentram muitos exemplos, enquanto várias categorias possuem amostras escassas.

Fonte: Proença e Simões (2020); distribuição calculada na partição de treino.

Como o TACO representa cada objeto


Imagem original



Segmentação
Fine



Caixas COCO



O JSON fornece


Máscara poligonal
Caixa delimitadora
Categoria Fine

Remapeamento

Paper cup →
Paper/Cardboard → Litter
Plastic lid → Plastic →
Litter

3 objetos e 3 classes Fine. O YOLO utiliza as caixas; as máscaras documentam a anotação original.

Desenho experimental controlado



Partição fixa

1.050 treino
225 validação
225 teste

YOLO26n

Entrada 640
Lote 24
Até 60 épocas

Sementes de treinamento

42, 123 e 2026

O que cada modelo reconhece

Exemplo de rótulo para uma mesma garrafa plástica

Modelo	Classes	Resposta esperada
Fine	60	Tipo específico: garrafa plástica
Material	6	Material: plástico
Binary	1	Presença de resíduo

Material: as seis classes

Plástico Metal Vidro
Papel/papelão Orgânico Outros

Agrupamento definido no projeto. Outros inclui materiais compostos ou não especificados.

Binary: uma classe, resíduo (*Litter*).

Como interpretar os resultados

AP_{50} : qualidade da detecção

Resume a relação entre precisão e recuperação de objetos ao variar a confiança. Exige a classe correta e sobreposição de pelo menos 50% com a caixa anotada.

F_1 : equilíbrio entre precisão e recall

Combina precisão e recall no melhor ponto por classe. O resultado agrega as classes por média.

Ambas variam de 0 a 1. Valores maiores indicam melhor desempenho segundo o critério avaliado.

Resultados dos modelos treinados

Três treinamentos por taxonomia: média $\pm$ desvio-padrão.

Modelo	AP_{50}	F_1
Fine (60 classes)	$0,103 \pm 0,007$	$0,168 \pm 0,016$
Material (6 classes)	$0,156 \pm 0,026$	$0,242 \pm 0,037$
Binary (1 classe)	$0,566 \pm 0,004$	$0,594 \pm 0,007$

Binary obtém os maiores valores, mas informa apenas onde há resíduo. Material preserva a composição e supera Fine na média.

Exemplo: lata prevista como aerossol

Exemplo ilustrativo: o objeto é uma lata de bebida, mas o Fine prevê aerossol. A caixa tem sobreposição suficiente.

Critério	O que é comparado	Resultado
Fine	Lata de bebida e aerossol	Erro
Material	Metal e metal	Acerto
Binary	Resíduo e resíduo	Acerto

A caixa permanece igual. A exigência sobre a classe diminui.

Esta avaliação reutiliza as saídas do Fine. Não há novo treinamento nem melhora da localização.

Mesmo Fine, rótulos mais amplos

Quanto o AP_{50} aumenta ao aceitar respostas menos específicas?

O que precisa acertar	AP_{50} médio	Ganho relativo
Tipo exato (Fine)	0,103	Referência
Material do resíduo	0,171	+ 65,8%
Presença de resíduo	0,466	+ 351,6%

As caixas são iguais. Muda o rótulo aceito como correto.

Como verificar se o ganho se repete

Três treinamentos por modelo

Sementes 42, 123 e 2026 alteram o componente aleatório do treinamento. A partição de dados permanece fixa.

Intervalo de confiança de 95% para o ganho

No bootstrap, as imagens de teste são sorteadas com repetição 2.000 vezes por semente, sem novo treinamento. Cada sorteio é igual para os dois métodos comparados.

Um intervalo totalmente acima de zero sustenta um ganho positivo. Se inclui zero, a comparação permanece inconclusiva.

Repetição dos ganhos nas três sementes

Comparação	AP ₅₀	F ₁
Material treinado supera Fine	1 de 3	3 de 3
Fine agrupado por material vs. Fine exato	3 de 3	3 de 3
Fine agrupado como resíduo vs. Fine exato	3 de 3	3 de 3

Cada célula conta execuções cujo IC95% do ganho ficou totalmente acima de zero.

Material melhora F_1 nas três execuções. Em AP₅₀, o suporte é limitado.

O efeito de agrupar os rótulos do Fine se repete nas três sementes.

Objetos não encontrados pelo Fine

O teste contém **637 objetos anotados** em 225 imagens.

	Objetos, em média	Proporção
Com detecção sobreposta	232,3	36,5%
Sem detecção sobreposta	404,7	63,5%

Agrupar classes não recupera os objetos que o Fine omitiu.

Média de três sementes. Confiância $\geq 0,25$, IoU $\geq 0,5$ e associação sem exigir a classe correta.

Classificação dos objetos localizados

Agora são consideradas apenas as **232,3 associações espaciais**, em média.


Resultado da classificação	Proporção
Classe Fine correta	43,05%
Classe errada, mesmo material	22,95%
Classe errada, material diferente	34,00%

Avaliar por material deixa de penalizar as confusões dentro do mesmo grupo. Confusões entre materiais continuam sendo erros.

Média de três sementes. Mesmo critério espacial do slide 13. As três proporções somam 100%.

Casos reais do teste Fine

Acerto




GT = Pred.: Other plastic bottle

Intra-material



GT: Drink can
Pred.: Aerosol

Inter-material



GT: Aluminium foil
Pred.: Other carton

Omissão



GT: Plastic lid
Pred.: nenhuma

GT em branco; predição em preto tracejado. Semente 42.

Conclusões e limites

Granularidade tem custo mensurável

Fine exige distinções difíceis em um conjunto pequeno e desbalanceado.

Material oferece um compromisso

Preserva informação de composição e melhora o F_1 macro.

Binary: maiores AP_{50} e F_1

Entre as configurações avaliadas, sem distinção de material.

Limites do estudo

- uma partição fixa
- conjunto de teste com 225 imagens
- agrupamento por material definido no projeto

A taxonomia deve acompanhar a informação exigida pela aplicação.