

UNIVERSIDADE FEDERAL DO PIAUÍ

O custo da granularidade semântica na detecção de resíduos

Estudo controlado com TACO e YOLO26n

Jean Carlos Rodrigues Sousa Karielly de Carvalho
Marcos A. G. B. Brito

UFPI – CSHNB, Picos-PI



Pergunta central

Como a granularidade das classes afeta a detecção em um conjunto pequeno e de cauda longa?

Localização

O modelo precisa encontrar o resíduo e delimitar sua posição.

Semântica

A mesma caixa pode ser penalizada quando recebe um rótulo incorreto.

O experimento mantém imagens, caixas, partição e treinamento constantes. Somente a taxonomia muda.

TACO e o problema de cauda longa

1.500


imagens em ambientes
reais

4.784

objetos anotados

60

classes Fine oficiais



Cauda longa

Poucas classes concentram muitos exemplos, enquanto várias categorias possuem amostras escassas.

Fonte: Proença e Simões (2020); distribuição calculada na partição de treino.

Como o TACO representa cada objeto

Imagem original



Segmentação
Fine



Caixas COCO



O JSON fornece


Máscara poligonal
Caixa delimitadora
Categoria Fine

Remapeamento

Drink can → Metal →
Litter

13 objetos e 10 classes Fine.
O YOLO utiliza as caixas; as
máscaras documentam a
anotação original.

Desenho experimental controlado



Mesma base

1.050 treino, 225 validação e 225 teste.

Mesmo detector

YOLO26n, entrada 640, lote 24, até 60 épocas.

Três repetições

Sementes 42, 123 e 2026.

Três níveis de detalhe semântico

60 Fine

Categorias oficiais, como lata de alumínio, garrafa de vidro e tampa plástica.

6 Material


Plastic, Metal, Glass, Paper/Cardboard, Organic e Other.

1 Binary

Todo objeto recebe o rótulo *Litter*. A tarefa preserva apenas resíduo versus fundo.

A redução de classes diminui a informação exigida do detector.

Desempenho dos modelos treinados



Resultado principal

Material melhora o F_1 em relação a Fine.

Binary apresenta o maior desempenho, mas elimina a informação de composição.

Barras: média de três sementes.

Uma predição, três critérios de acerto

Avaliação	Quando a detecção conta como correta	AP ₅₀
Fine	classe exata, entre 60 categorias	0,103 ± 0,007
Material	material correto, entre seis grupos	0,171 ± 0,015
Binary	qualquer resíduo corretamente localizado	0,466 ± 0,014

Rótulos mais amplos recuperam detecções já localizadas.

Evidência estatística nas três sementes

Comparação	ΔAP_{50}	Suporte	ΔF_1	Suporte
Material treinado vs. Fine	$+0,051 \pm 0,022$	1/3	$+0,074 \pm 0,027$	3/3
Fine → Material (mesmas caixas)	$+0,068 \pm 0,012$	3/3	$+0,101 \pm 0,008$	3/3
Fine → Binary (mesmas caixas)	$+0,345 \pm 0,016$	3/3	$+0,318 \pm 0,011$	3/3

Δ = **ganho médio** $\pm$ **DP**

Diferença positiva favorece a taxonomia mais simples.

Suporte = sementes com IC95% > 0

3/3 indica repetição da evidência nas três execuções.

Os erros semânticos não explicam tudo

56,95%

dos casamentos espaciais recebem

classe Fine incorreta **63,5%**

dos 637 objetos de teste são omitidos


Duas limitações coexistem

- confusão entre rótulos visualmente próximos
- cobertura espacial insuficiente, sobretudo por omissões

Média de três sementes, confiança 0,25 e $\text{IoU} \geq 0,5$ para casamentos espaciais.

Casos reais do teste Fine

Acerto



GT = Pred.: Other plastic bottle

Intra-material



GT: Drink can
Pred.: Aerosol

Inter-material



GT: Aluminium foil
Pred.: Other carton

Omissão



GT: Plastic lid
Pred.: nenhuma

GT em branco; predição em preto tracejado. Semente 42.

Conclusões e limites

Granularidade tem custo mensurável

Fine exige distinções difíceis em um conjunto pequeno e desbalanceado.

Material oferece um compromisso

Preserva informação de composição e melhora o ponto operacional.

Binary maximiza a detectabilidade

Sem distinção entre materiais.

Limites do estudo

- uma partição fixa
- conjunto de teste com 225 imagens
- agrupamento por material definido no projeto

A taxonomia deve acompanhar a informação exigida pela aplicação.