

UNIVERSIDADE FEDERAL DO PIAUÍ

O custo da granularidade semântica na detecção de resíduos

Estudo controlado com TACO e YOLO26n

Jean Carlos Rodrigues Sousa Karielly de Carvalho
Marcos A. G. B. Brito

UFPI – CSHNB, Picos–PI



Pergunta central

Como a granularidade das classes afeta a detecção em um conjunto pequeno e de cauda longa?

Localização

O modelo precisa encontrar o resíduo e delimitar sua posição.

Semântica

A mesma caixa pode ser penalizada quando recebe um rótulo incorreto.

O experimento mantém imagens, caixas, partição e treinamento constantes. Somente a taxonomia muda.

TACO e o problema de cauda longa

1.500


imagens em ambientes
reais

4.784

objetos anotados

60

classes Fine oficiais



Cauda longa

Poucas classes concentram muitos exemplos, enquanto várias categorias possuem amostras escassas.

Fonte: Proença e Simões (2020); distribuição calculada na partição de treino.

Como o TACO representa cada objeto


Imagem original



Segmentação
Fine



Caixas COCO



O JSON fornece


Máscara poligonal
Caixa delimitadora
Categoria Fine

Remapeamento

Paper cup →
Paper/Cardboard → Litter
Plastic lid → Plastic →
Litter

3 objetos e 3 classes Fine. O YOLO utiliza as caixas; as máscaras documentam a anotação original.

Desenho experimental controlado



Partição fixa

1.050 treino
225 validação
225 teste

YOLO26n

Entrada 640
Lote 24
Até 60 épocas

Sementes

42, 123 e 2026

O que cada modelo reconhece

Exemplo de rótulo para uma mesma garrafa plástica

Modelo	Classes	Resposta esperada
Fine	60	Tipo específico: garrafa plástica
Material	6	Material: plástico
Binary	1	Presença de resíduo

Material reúne plástico, metal, vidro, papel/papelão, orgânico e outros. Binary mantém uma classe de objeto, além do fundo.

Quanto mais amplo o rótulo, menos detalhes o modelo precisa distinguir.

Como interpretar os resultados

AP_{50} : qualidade da detecção

Resume a relação entre precisão e recuperação de objetos ao variar a confiança. Exige a classe correta e sobreposição de pelo menos 50% com a caixa anotada.

F_1 : equilíbrio entre precisão e recall

Combina a proporção de detecções corretas com a proporção de objetos recuperados em um ponto de operação.

Ambas variam de 0 a 1. Valores maiores indicam melhor desempenho segundo o critério avaliado.

Resultados dos modelos treinados

Cada linha corresponde a um treinamento com uma taxonomia diferente.

Modelo	AP_{50}	F_1
Fine (60 classes)	$0,146 \pm 0,022$	$0,232 \pm 0,005$
Material (6 classes)	$0,183 \pm 0,023$	$0,296 \pm 0,006$
Binary (1 classe)	$0,567 \pm 0,002$	$0,593 \pm 0,004$

Binary obtém os maiores valores, mas informa apenas onde há resíduo. Material preserva a composição e supera Fine na média.

Média $\pm$ desvio-padrão de três sementes. Avaliação nativa do Ultralytics. As tarefas exigem níveis diferentes de detalhe.

Exemplo: lata prevista como aerossol

Exemplo ilustrativo: o objeto é uma lata de bebida, mas o Fine prevê aerossol. A caixa tem sobreposição suficiente.

Critério	O que é comparado	Resultado
Fine	Lata de bebida e aerossol	Erro
Material	Metal e metal	Acerto
Binary	Resíduo e resíduo	Acerto

A caixa permanece igual. A exigência sobre a classe diminui.

Esta avaliação reutiliza as saídas do Fine. Não há novo treinamento nem melhora da localização.

Fine com classes agrupadas

Todas as linhas usam as mesmas caixas e confianças. Os rótulos previstos e os rótulos de referência são agrupados.

Exigência de classe	AP ₅₀
Tipo exato (Fine)	0,103 ± 0,007
Material correto	0,171 ± 0,015
Presença de resíduo	0,466 ± 0,014

Parte da penalização vem de distinguir classes, mesmo quando o objeto está localizado.

Média ± desvio-padrão. Avaliador próprio comum aos três critérios. Os valores desta tabela não são diretamente comparáveis à avaliação nativa do slide 8.

Como verificar se o ganho se repete

Três treinamentos por modelo

Sementes 42, 123 e 2026 alteram o componente aleatório do treinamento. A partição de dados permanece fixa.

Intervalo de confiança de 95% para o ganho

O bootstrap reamostra as mesmas imagens para os dois métodos comparados. Cada semente recebe 2.000 reamostragens.

Um intervalo totalmente acima de zero sustenta um ganho positivo. Se inclui zero, a comparação permanece inconclusiva.

Repetição dos ganhos nas três sementes

Comparação	AP_{50}	F_1
Material treinado supera Fine	1 de 3	3 de 3
Fine agrupado por material vs. Fine exato	3 de 3	3 de 3
Fine agrupado como resíduo vs. Fine exato	3 de 3	3 de 3

Cada célula conta execuções cujo IC95% do ganho ficou totalmente acima de zero. Avaliador próprio para todas as comparações.

Material melhora F_1 nas três execuções. Em AP_{50} , o suporte é limitado.

O efeito de agrupar os rótulos do Fine se repete nas três sementes.

Objetos não encontrados pelo Fine

O teste contém **637 objetos anotados** em 225 imagens.

	Objetos, em média	Proporção
Com detecção sobreposta	232,3	36,5%
Sem detecção sobreposta	404,7	63,5%

Agrupar classes não recupera os objetos que o Fine omitiu.

Média de três sementes. Confiância $\geq 0,25$, IoU $\geq 0,5$ e associação sem exigir a classe correta.

Classificação dos objetos localizados

Agora são consideradas apenas as **232,3 associações espaciais**, em média.


Resultado da classificação	Proporção
Classe Fine correta	43,05%
Classe errada, mesmo material	22,95%
Classe errada, material diferente	34,00%

Avaliar por material deixa de penalizar as confusões dentro do mesmo grupo. Confusões entre materiais continuam sendo erros.

Média de três sementes. Mesmo critério espacial do slide 13. As três proporções somam 100%.

Casos reais do teste Fine

Acerto



GT = Pred.: Other plastic bottle

Intra-material



GT: Drink can
Pred.: Aerosol

Inter-material



GT: Aluminium foil
Pred.: Other carton

Omissão



GT: Plastic lid
Pred.: nenhuma

GT em branco; predição em preto tracejado. Semente 42.

Conclusões e limites

Granularidade tem custo mensurável

Fine exige distinções difíceis em um conjunto pequeno e desbalanceado.

Material oferece um compromisso

Preserva informação de composição e melhora o ponto operacional.

Binary maximiza a detectabilidade

Sem distinção entre materiais.

Limites do estudo

- uma partição fixa
- conjunto de teste com 225 imagens
- agrupamento por material definido no projeto

A taxonomia deve acompanhar a informação exigida pela aplicação.