

UNIVERSIDADE FEDERAL DO PIAUÍ

# O custo da granularidade semântica na detecção de resíduos

Estudo controlado com TACO e YOLO26n

Jean Carlos Rodrigues Sousa   Karielly de Carvalho  
Marcos A. G. B. Brito

UFPI – CSHNB, Picos–PI



# Pergunta central

---

## Como a granularidade das classes afeta a detecção em um conjunto pequeno e de cauda longa?

### Localização

O modelo precisa encontrar o resíduo e delimitar sua posição.

### Semântica

A mesma caixa pode ser penalizada quando recebe um rótulo incorreto.

O experimento mantém imagens, caixas, partição e treinamento constantes. Somente a taxonomia muda.

# TACO e o problema de cauda longa

1.500


imagens em ambientes  
reais

4.784

objetos anotados

60

classes Fine oficiais



## Cauda longa

Poucas classes concentram muitos exemplos, enquanto várias categorias possuem amostras escassas.

Fonte: Proença e Simões (2020); distribuição calculada na partição de treino.

# Como o TACO representa cada objeto


Imagem original



Segmentação  
Fine



Caixas COCO



## O JSON fornece


Máscara poligonal  
Caixa delimitadora  
Categoria Fine

## Remapeamento

Paper cup →  
Paper/Cardboard → Litter  
Plastic lid → Plastic →  
Litter

3 objetos e 3 classes Fine. O YOLO utiliza as caixas; as máscaras documentam a anotação original.

# Desenho experimental controlado



## Partição fixa

1.050 treino  
225 validação  
225 teste

## YOLO26n

Entrada 640  
Lote 24  
Até 60 épocas

## Sementes

42, 123 e 2026

# O que cada modelo reconhece

Exemplo de rótulo para uma mesma garrafa plástica

| Modelo   | Classes | Resposta esperada                 |
|----------|---------|-----------------------------------|
| Fine     | 60      | Tipo específico: garrafa plástica |
| Material | 6       | Material: plástico                |
| Binary   | 1       | Presença de resíduo               |

## Material: as seis classes

Plástico Metal Vidro  
Papel/papelão Orgânico Outros

Agrupamento definido no projeto. Outros inclui materiais compostos ou não especificados.

**Binary:** uma classe, resíduo (*Litter*).

# Como interpretar os resultados

---

## **$AP_{50}$ : qualidade da detecção**

Resume a relação entre precisão e recuperação de objetos ao variar a confiança. Exige a classe correta e sobreposição de pelo menos 50% com a caixa anotada.

## **$F_1$ : equilíbrio entre precisão e recall**

Combina a proporção de detecções corretas com a proporção de objetos recuperados em um ponto de operação.

Ambas variam de 0 a 1. Valores maiores indicam melhor desempenho segundo o critério avaliado.

# Resultados dos modelos treinados

Cada linha corresponde a um treinamento com uma taxonomia diferente.

| Modelo               | $AP_{50}$         | $F_1$             |
|----------------------|-------------------|-------------------|
| Fine (60 classes)    | $0,146 \pm 0,022$ | $0,232 \pm 0,005$ |
| Material (6 classes) | $0,183 \pm 0,023$ | $0,296 \pm 0,006$ |
| Binary (1 classe)    | $0,567 \pm 0,002$ | $0,593 \pm 0,004$ |

Binary obtém os maiores valores, mas informa apenas onde há resíduo. Material preserva a composição e supera Fine na média.

Média  $\pm$  desvio-padrão de três sementes. Avaliação nativa do Ultralytics. As tarefas exigem níveis diferentes de detalhe.

# Exemplo: lata prevista como aerossol

**Exemplo ilustrativo:** o objeto é uma lata de bebida, mas o Fine prevê aerossol. A caixa tem sobreposição suficiente.

| <b>Critério</b> | <b>O que é comparado</b>  | <b>Resultado</b> |
|-----------------|---------------------------|------------------|
| Fine            | Lata de bebida e aerossol | Erro             |
| Material        | Metal e metal             | Acerto           |
| Binary          | Resíduo e resíduo         | Acerto           |

**A caixa permanece igual. A exigência sobre a classe diminui.**

Esta avaliação reutiliza as saídas do Fine. Não há novo treinamento nem melhora da localização.

# Mesmo Fine, rótulos mais amplos

Quanto o  $AP_{50}$  aumenta ao aceitar respostas menos específicas?

| O que precisa acertar | $AP_{50}$ médio | Ganho relativo  |
|-----------------------|-----------------|-----------------|
| Tipo exato (Fine)     | 0,103           | Referência      |
| Material do resíduo   | 0,171           | + <b>65,8%</b>  |
| Presença de resíduo   | 0,466           | + <b>351,6%</b> |

**As caixas são iguais. Muda o rótulo aceito como correto.**

$AP_{50}$  médio: três sementes, avaliador controlado (diferente do slide 8).

Ganho relativo ao Fine, não proporção de objetos corretos.

# Como verificar se o ganho se repete

---

## Três treinamentos por modelo

Sementes 42, 123 e 2026 alteram o componente aleatório do treinamento. A partição de dados permanece fixa.

## Intervalo de confiança de 95% para o ganho

O bootstrap reamostra as mesmas imagens para os dois métodos comparados. Cada semente recebe 2.000 reamostragens.

Um intervalo totalmente acima de zero sustenta um ganho positivo. Se inclui zero, a comparação permanece inconclusiva.

# Repetição dos ganhos nas três sementes

| Comparação                                | $AP_{50}$ | $F_1$  |
|-------------------------------------------|-----------|--------|
| Material treinado supera Fine             | 1 de 3    | 3 de 3 |
| Fine agrupado por material vs. Fine exato | 3 de 3    | 3 de 3 |
| Fine agrupado como resíduo vs. Fine exato | 3 de 3    | 3 de 3 |

Cada célula conta execuções cujo IC95% do ganho ficou totalmente acima de zero. Avaliador próprio para todas as comparações.

Material melhora  $F_1$  nas três execuções. Em  $AP_{50}$ , o suporte é limitado.

**O efeito de agrupar os rótulos do Fine se repete nas três sementes.**

# Objetos não encontrados pelo Fine

O teste contém **637 objetos anotados** em 225 imagens.

|                         | Objetos, em média | Proporção |
|-------------------------|-------------------|-----------|
| Com detecção sobreposta | 232,3             | 36,5%     |
| Sem detecção sobreposta | 404,7             | 63,5%     |

**Agrupar classes não recupera os objetos que o Fine omitiu.**

Média de três sementes. Confiância  $\geq 0,25$ , IoU  $\geq 0,5$  e associação sem exigir a classe correta.

# Classificação dos objetos localizados

Agora são consideradas apenas as **232,3 associações espaciais**, em média.


| Resultado da classificação        | Proporção |
|-----------------------------------|-----------|
| Classe Fine correta               | 43,05%    |
| Classe errada, mesmo material     | 22,95%    |
| Classe errada, material diferente | 34,00%    |

Avaliar por material deixa de penalizar as confusões dentro do mesmo grupo. Confusões entre materiais continuam sendo erros.

Média de três sementes. Mesmo critério espacial do slide 13. As três proporções somam 100%.

# Casos reais do teste Fine

Acerto




**GT = Pred.:** Other plastic bottle

Intra-material



**GT:** Drink can  
**Pred.:** Aerosol

Inter-material



**GT:** Aluminium foil  
**Pred.:** Other carton

Omissão



**GT:** Plastic lid  
**Pred.:** nenhuma

GT em branco; predição em preto tracejado. Semente 42.

# Conclusões e limites

---

## Granularidade tem custo mensurável

Fine exige distinções difíceis em um conjunto pequeno e desbalanceado.

## Material oferece um compromisso

Preserva informação de composição e melhora o ponto operacional.

## Binary maximiza a detectabilidade

Sem distinção entre materiais.

## Limites do estudo

- uma partição fixa
- conjunto de teste com 225 imagens
- agrupamento por material definido no projeto

A taxonomia deve acompanhar a informação exigida pela aplicação.